UNIVERSIDAD CATOLICA DEL MAULE

Nota

Evaluación 2 – 35%

Nombres	
Carrera	**Ingeniería Civil Informática**
Actividad Curricular	**INF-522**
Académicos	**Natalia Morales** **Sebastián Farías**
Fecha de Entrega	**01-11-2026**
Fecha de Presentación	**05-11-2026**

Resultados de Aprendizajes Evaluados:	Utilizar los conceptos básicos de herramientas que permitan diseñar indicadores de gestión (Datawarehouse, minería de datos, consultas complejas).
Indicadores de Evaluación:	○ Identifica los elementos fundamentales de la estrategia de sistemas de información. ○ Distingue los tipos de almacenamientos de los sistemas de información OLTP (proceso transaccional). ○ Utiliza técnicas de depuración y extracción de datos desde bases de datos fuentes a esquemas globales.

INSTRUCCIONES PARA EL DESARROLLO DE LA EVALUACIÓN
Para el desarrollo de su evaluación debe considerar lo siguiente: **Evaluación Grupal:** **1. La actividad consiste en construir procesos ETL en Python, orquestados con Apache Airflow, que consuman APIs públicas de datos abiertos de Chile y carguen los datos en PostgreSQL para calcular indicadores de gestión.** **2. La actividad puede ser desarrollada en grupos de no más de 3 personas, los integrantes del grupo pueden ser de secciones distintas.** **3. Este trabajo incluye presentación, la cual incluye preguntas a cada uno de los integrantes del grupo. La presentación es obligatoria: el estudiante que no se presente obtendrá la nota mínima (1,0).** **4. Restricciones: los ETL se programan en Python; la base de datos destino es PostgreSQL y la orquestación se realiza con Apache Airflow. Los datos deben obtenerse mediante API (no se acepta la descarga manual de archivos). No se deben incluir contraseñas ni claves de API en el código ni en la carpeta entregada.**

UNIVERSIDAD CATOLICA DEL MAULE

1. **Se aplicará artículo 67º del reglamento del estudiante, el cual indica que, en caso de sorprender copia parcial o exacta, ya sea entre compañeros o reproducidos de algún medio, lo cual implica un 1,0 para todos los involucrados.**
2. **Si hay algún requerimiento sin contestar, y en la rúbrica no se puede observar, no aplica puntaje.**

ÍTEM 1. Desarrollo del Caso: estrategia de datos e indicadores de gestión con APIs públicas de Chile

Contexto

Un equipo de analítica de datos debe construir una solución que permita medir la gestión de una institución o sector que publica datos abiertos en Chile. Cada grupo elegirá, de forma autónoma, al menos dos APIs públicas, diseñará procesos ETL en Python que las consuman, cargará los datos en PostgreSQL y calculará indicadores de gestión. Todo el flujo debe estar orquestado con Apache Airflow, de modo que la falla de una fuente no detenga el resto del proceso.

Objetivos:

1. Buscar, seleccionar y justificar APIs públicas de datos abiertos de Chile.
2. Implementar ETL en Python (extracción, transformación y carga) hacia un modelo de datos en PostgreSQL.
3. Diseñar una estrategia de ejecución en Airflow con DAGs independientes, reintentos y tolerancia a fallas.
4. Definir y calcular indicadores de gestión sobre los datos cargados.
5. Formular una estrategia de datos para la solución: cómo asegurar la calidad de los datos, de dónde provienen y cómo se transforman, qué riesgos existen y cómo podría crecer la solución.

UNIVERSIDAD CATOLICA DEL MAULE

Instrucciones para desarrollar el caso

1. Selección de fuentes

- Cada grupo busca y elige al menos 2 APIs públicas de datos abiertos de Chile (por ejemplo, datos.gob.cl, Mercado Público, CMF, Banco Central, mindicador.cl u otras). Los datos deben obtenerse por API, no por descarga manual de archivos.
- **Los links de API elegidos no deben coincidir con los de otro grupo. Si la API requiere clave, el grupo debe tramitarla con anticipación.**

2. Extracción (Extract) en Python

- Consumir cada API desde Python (por ejemplo, con la librería requests) y guardar la respuesta tal como llega en el esquema raw de PostgreSQL, junto con la fecha y hora de la extracción.
- El código debe considerar que una API puede devolver errores, entregar los datos por páginas o limitar la cantidad de consultas.

3. Transformación (Transform)

Limpiar y preparar los datos de la capa raw antes de cargarlos al modelo de datos.

Qué tipo de transformaciones se pueden realizar:

- Renombrar campos
- Conversión de tipos de datos (fechas, números)
- Normalización de textos y valores
- Tratamiento de nulos y valores atípicos
- Eliminación de duplicados
- Creación de campos calculados
- Mapeo y recodificación de valores (por ejemplo, códigos a descripciones)
- Agregación y filtrado de registros
- Validaciones de calidad antes de cargar al modelo

4. Carga (Load) y modelo de datos en PostgreSQL

- Organizar la base en esquemas: raw (datos crudos), staging (datos limpios), dw (modelo dimensional) y mart (indicadores).
- El modelo dimensional debe tener al menos una tabla de hechos y dos dimensiones, incluyendo una dimensión de tiempo, con claves y tipos de datos definidos. Se entrega el DDL.
- Las cargas deben ser idempotentes: volver a ejecutar un DAG no debe duplicar registros (por ejemplo, con INSERT ... ON CONFLICT o reemplazo por partición de fecha).

5. Orquestación y estrategia de ejecución en Apache Airflow

- Se exigen al menos 3 DAGs: un DAG de ETL independiente por cada API y un DAG de indicadores que calcula los KPIs en SQL sobre las tablas cargadas.
- **Validación previa:** comprobar que la API responde antes de extraer (tarea de validación).
- **Programación:** definir un schedule justificado según la periodicidad de la fuente y poder recargar un rango de fechas pasado.
- **Auditoría y alertas:** registrar cada ejecución en una tabla (por ejemplo, etl_audit con DAG, run_id, filas leídas y cargadas, % de nulos, duración y estado) y dejar registro de las fallas (on_failure_callback o equivalente).

- **Demostración de falla:** durante la presentación, el grupo provoca una falla controlada en una tarea (por ejemplo, una URL incorrecta) y muestra los reintentos, que el resto del flujo continúa y cómo se recupera.

6. Indicadores de gestión

- Definir de **4 a 6 indicadores** que respondan a una pregunta de gestión sobre el sector elegido.
- Cada indicador se documenta con: nombre, objetivo o decisión que apoya, fórmula, fuente(s), periodicidad y meta o umbral.
- Se calculan con consultas SQL sobre el modelo (esquema mart) y se presentan en el informe como tablas o gráficos. No se exige un dashboard.

7. Estrategia de datos

Capítulo del informe de 2 a 3 páginas que aborde, como mínimo:

- Qué decisiones apoyan los indicadores y quién los usaría.
- Calidad de datos: nulos, duplicados, consistencia entre fuentes.
- Origen de los datos: de dónde viene cada dato y cómo se transforma hasta llegar al indicador.
- Frecuencia de actualización y su relación con el schedule de los DAGs.
- Riesgos: cambios en la API, límites de uso, licencias y datos personales o sensibles.
- Escalabilidad: cómo crecería la solución (más fuentes, más volumen, más indicadores).

Adicionalmente, se debe realizar y adjuntar al informe:

Información de carga (obtenida de la tabla de auditoría):

- Cantidad de registros cargados por tabla
- Porcentaje de registros con errores o nulos
- Tiempo de ejecución de cada DAG

Análisis del proceso (como mínimo):

- ¿Qué hallazgos surgieron al cargar los datos?
- ¿Qué problemas detectaron y cómo los resolvieron?
- ¿Qué fallas ocurrieron en las APIs o en Airflow y cómo respondió el diseño de los DAGs?

ENTREGABLES:

1. **Informe en PDF** con evidencia del proceso. Debe contener, al menos:
    - Portada e introducción.
    - Fuentes seleccionadas y su justificación.
    - Paso a paso de la solución: extracción, transformación, carga y modelo de datos.
    - Diseño de los DAGs y estrategia de ejecución: diagrama de dependencias, capturas de Airflow con ejecuciones exitosas y fallidas, y logs relevantes.
    - Indicadores de gestión y estrategia de datos.
    - Información de carga, análisis del proceso y conclusiones.
2. **Carpeta comprimida (.zip)** con los DAGs, los scripts de Python, el DDL de PostgreSQL.
3. **Presentación de apoyo** en PowerPoint (.pptx) o PDF para la exposición, de 8 a 12 láminas: problema y fuentes, arquitectura, diseño de DAGs, modelo de datos, indicadores y hallazgos, estrategia de datos y lecciones aprendidas. Se entrega junto con el informe.
4. **Exposición grupal:**

- **Modalidad:** la presentación será grupal, con todos los integrantes exponiendo en conjunto el trabajo realizado en Python, Airflow y PostgreSQL, apoyados en la presentación PowerPoint e incluyendo la demostración de falla controlada.
- **Duración:** cada grupo dispondrá de 8 minutos para presentar y posteriormente vendrá una ronda de preguntas a cada integrante.

UNIVERSIDAD CATOLICA DEL MAULE

Parte 1: Informe técnico y solución ETL en Airflow y PostgreSQL (30%)

Indicadores	Valores				Observaciones
	Destacado (5 puntos)	**Competente (4 puntos)**	**Básico (3 puntos)**	**En desarrollo (1 punto)**	
Informe escrito y carpeta comprimida (estructura, evidencia y reproducibilidad)	Informe con todos los apartados solicitados y evidencia completa (capturas de Airflow, logs, consultas); carpeta comprimida que se puede reproducir con el README.	Informe con la mayoría de los apartados y evidencia suficiente; carpeta ejecutable con ajustes menores.	Informe con apartados faltantes o evidencia limitada; carpeta incompleta o difícil de reproducir.	Informe sin estructura clara, con evidencia mínima o sin la carpeta con el código.	
Selección y justificación de fuentes	Al menos 2 APIs públicas de Chile, bien justificadas (viabilidad, documentación, límites, volumen), con campo de cruce claro y links de API propios (no repetidos con otros grupos).	2 APIs adecuadas; justificación parcial o cruce poco explicado.	Fuentes válidas pero con justificación débil o cruce forzado entre ellas.	Solo 1 API o fuentes que no cumplen los criterios de viabilidad (por ejemplo, descarga manual de archivos).	
Extracción y transformación en Python	Extracción robusta (autenticación, paginación, límites de uso y errores HTTP) y transformaciones documentadas con validaciones de calidad; métricas de carga completas.	Extracción y transformación funcionales con manejo básico de errores; métricas de carga parciales.	La extracción funciona, pero con limpieza mínima, sin manejo de errores ni métricas.	Extracción incompleta o datos sin depurar; no se reportan métricas.	
Modelo de datos en PostgreSQL	Capas raw, staging, dw y mart; modelo dimensional coherente (hechos, dimensiones, claves y tipos) y carga idempotente.	Modelo dimensional funcional con errores menores; carga mayormente idempotente.	Modelo incompleto (sin dimensiones o sin capas separadas) o cargas que duplican datos.	Datos cargados sin un modelo definido.	

UNIVERSIDAD CATOLICA DEL MAULE

Indicadores	Valores				Observaciones
	Destacado (5 puntos)	**Competente (4 puntos)**	**Básico (3 puntos)**	**En desarrollo (1 punto)**	
Diseño de DAGs y orquestación en Airflow	Un DAG independiente por API y un DAG de indicadores disparado automáticamente; dependencias, schedule y configuración (Connections y Variables) correctos y justificados.	DAGs por fuente y de indicadores funcionales; dependencias o programación poco justificadas.	Menos de 3 DAGs o DAGs acoplados entre sí; configuración dentro del código.	Los procesos no están orquestados en Airflow o los DAGs no ejecutan.	
Tolerancia a fallas y ejecución en Airflow	Reintentos con espera, timeouts, validación previa de la API, registro de fallas y tabla de auditoría; el resto del flujo continúa ante una falla y se demuestra en vivo.	Reintentos y registro de fallas configurados; la falla de un DAG no detiene a los otros, pero sin auditoría completa.	Reintentos básicos, sin aislamiento de fallas ni auditoría; demostración de falla parcial.	Sin manejo de fallas: un error detiene todo el flujo.	
Indicadores de gestión	De 4 a 6 indicadores relevantes, con definición completa (objetivo, fórmula, fuente, periodicidad y meta), calculados correctamente en SQL sobre el modelo.	De 4 a 6 indicadores bien calculados, con definiciones incompletas.	Menos de 4 indicadores o con errores de cálculo o de definición.	Indicadores sin definición o sin sustento en los datos cargados.	
Estrategia de datos	Aborda decisiones que apoyan los indicadores, calidad, origen de los datos, frecuencia de actualización, riesgos y escalabilidad, con fundamento en el trabajo realizado.	Aborda la mayoría de los elementos con fundamento adecuado.	Aborda pocos elementos o de forma genérica, sin vínculo con la solución.	No se incluye o se limita a enunciados generales.	

UNIVERSIDAD CATOLICA DEL MAULE

Parte 2 – Presentación grupal y preguntas individuales (70%)

Indicadores	Valores				Observaciones
	Destacado (5 puntos)	**Competente (4 puntos)**	**Básico (3 puntos)**	**En desarrollo (1 punto)**	
Presentación grupal (evaluación colectiva – 30%)	Presentación clara, estructurada y bien organizada, apoyada en una presentación PowerPoint; exposición fluida y seguridad al mostrar los DAGs en Airflow, el ETL y los indicadores.	Presentación cubre la mayoría de puntos, aunque con vacíos de claridad.	Presentación incompleta o poco clara.	No se logra explicar adecuadamente el proceso ni mostrar resultados.	
Preguntas individuales (evaluación por estudiante – 40%)	Cada integrante responde con claridad, precisión técnica y dominio total del proceso.	Responde adecuadamente, aunque con explicaciones menos detalladas.	El estudiante responde de manera incompleta y con vacíos de comprensión.	El estudiante no responde o demuestra escaso dominio del proceso.	

Ponderación final:

- Parte 1: Informe + solución ETL en Airflow y PostgreSQL (evaluación grupal) → 30%
- Parte 2: Presentación grupal (30%) + Preguntas individuales (40%) → 70%

Ejemplo de cálculo de nota con la rúbrica (30% Informe + Solución ETL / 70% Presentación + Preguntas)

Parte 1 – Informe + Solución ETL (30%)

- Grupo obtiene: Informe = 4, Fuentes = 5, Python = 4, Modelo = 4, DAGs = 5, Tolerancia a fallas = 3, Indicadores = 4, Estrategia = 3 → 32/40 = 80%
- Ponderado: 80 × 0.30 = 24

Parte 2 – Presentación + Preguntas (70%)

- Presentación grupal = 4 → 80%
- Preguntas:
  - Est. A = 5 → 100%
  - Est. B = 3 → 60%
  - Est. C = 4 → 80%

Ponderados:

- Est. A: (80×0.30) + (100×0.40) = 64
- Est. B: (80×0.30) + (60×0.40) = 48
- Est. C: (80×0.30) + (80×0.40) = 56

Nota final (Parte 1 + Parte 2):

- Est. A: 24 + 64 = 88% → 6,16
- Est. B: 24 + 48 = 72% → 5,04
- Est. C: 24 + 56 = 80% → 5,6